

근로기준법 판례 기반 크로스 인코더 학습 데이터셋

원본 데이터: Final_DB_data.json (판례 요약본 2,439건)

조항 기준: 근로기준법_조항_요약_.csv (제1조~제116조)

최종 판례 수: **2,369건** | 테마 수: **256개** | 학습 페어: **768쌍**

1. 프로젝트 개요

본 데이터셋은 대한민국 근로기준법 판례(2,439건)를 원본으로, 크로스 인코더 모델 학습을 위해 구축된 판례 기반 독소조항 분류 학습 데이터입니다.

1단계에서 판례 내용을 현행 근로기준법 제1조~제116조에 의미적으로 매핑하고, 2단계에서 조항별 법적 쟁점(테마)을 세분화하여 각 테마별 대표 판례를 추출하였습니다. 최종 산출물은 **positive / hard_negative / easy_negative** 3쌍으로 구성된 학습 데이터셋입니다.

1.1 데이터셋 기본 정보

항목	내용
데이터셋 이름	근로기준법 판례 기반 크로스 인코더 학습 데이터셋
원본 판례 데이터	Final_DB_data.json (2,439건, 판례 요약본)
조항 기준 파일	근로기준법_조항_요약_.csv (제1조~제116조)
1단계 매핑 결과	2,396건 (중복 43건 제거)
2단계 분류 결과	2,369건 (미분류 27건 제외)
최종 테마 수	256개 (71개 조항 × 평균 3.6개)
대표 판례 수	256개 (테마별 1개)
총 학습 페어 수	768쌍 (항목당 3쌍: positive / hard_negative / easy_negative)
생성일	2026년 4월 20일

1.2 Tier 별 생성 전략

전체 조항을 판례 밀도에 따라 3개 Tier로 분류하여 차등 테마 분류 전략을 적용하였습니다.

Tier	대상 조항	조항 수	판례 수	테마 수	생성 기준
Tier 1	제2조, 제23조, 제34조, 제78조 등 핵심 조항	6개	1,411건	118개	10개 이상 세밀 분류
Tier 2	판례 10건 이상 일반 조항	21개	837건	94개	3~7개 주요 쟁점 분류
Tier 3	판례 10건 미만 희소 조항	44개	121건	44개	조항명 = 테마 (1개)

2. 데이터 구조

2.1 JSON 스키마

각 항목은 아래 JSON 구조를 가집니다.

필드	타입	설명
article	String	조항명 (예: 제23조(해고 제한))
theme	String	테마명 (사실관계 + 법적 쟁점 형식)
toxic_clause	String	독소 계약 문구 (법 위반·탈법적 조항 패턴)
training_data	Array[3]	학습 페어 배열 (positive 1개, hard_negative 1개, easy_negative 1개)
└ case_no	String	판례 사건번호
└ content	String	판례내용(요약) 텍스트
└ label	Int (0/1)	1 = 관련(positive), 0 = 비관련(negative)
└ type	String	positive / hard_negative / easy_negative

2.2 학습 페어 유형

유형	설명
positive	독소 계약 문구와 직접 관련된 테마의 대표 판례 (label=1). 해당 독소조항이 위반하는 법 원칙을 실제 판례로 학습하도록 설계.
hard_negative	동일 조항 내 다른 테마의 대표 판례 (label=0). 키워드는 유사하나 법적 쟁점이 다른 사례로, 모델의 세밀한 구분 능력을 훈련.
easy_negative	다른 조항의 판례 (label=0). 쟁점 자체가 다른 사례를 사용하여 기본 분류 능력 학습에 활용.

학습 비율: Positive 1 : Negative 2 (hard + easy) — 크로스 인코더 표준 1:2 전략 적용

3. 1 단계: 판례-조항 매핑 프로세스

기존 판례의 "위반조항" 컬럼(법 개정 전 기준)을 무시하고, 판례내용(요약) 텍스트를 분석하여 현행 근로기준법 조항에 의미적으로 재매핑하였습니다.

단계	처리 내용	입력	출력
원본 데이터 확인	JSON 구조 파악 및 기존 위반조항 컬럼 분포 분석	2,439건	분포 확인
배치 매핑 (5배치)	판례 내용 기반 현행 조항 의미 매핑 (500건 단위)	500건/배치	조항 태그 부여
구법 조항 보정	구 제14조(근로자 정의) → 현행 제2조 자동 보정	전 배치	정확도 향상
중복 제거	동일 사건번호 중복 판례 43건 제거	2,439건	2,396건
미분류 제외	타법(퇴직급여보장법·파견법 등) 전용 27건 제외	2,396건	2,369건

3.1 매핑 핵심 원칙

- 기존 위반조항 컬럼 사용 금지: 법 개정 전 번호 체계를 완전히 배제
- 내용 기반 매핑: 판례내용(요약)의 핵심 쟁점 키워드로 현행 조항에 의미 매핑
- 단일 조항 원칙: 가장 주된 쟁점 기준으로 단 하나의 조항에만 매핑
- 타법 처리: 산재보험법·퇴직급여보장법 등 타법 전용 판례는 미분류 처리
- 구법 보정: 구 제 14 조(근로자 정의)는 현행 제 2 조로 자동 변환

3.2 조항별 매핑 결과 (상위 10 개)

조항	판례 수	비율	Tier
제2조(근로자·평균임금·근로계약)	701건	29.6%	Tier 1
제23조(해고 제한)	294건	12.4%	Tier 1
제78조(요양 보상)	233건	9.8%	Tier 1
제34조(퇴직급여)	183건	7.7%	Tier 1
제43조(임금 지급)	113건	4.8%	Tier 2
제50조(주 근로시간)	93건	3.9%	Tier 2
제38조(우선 변제)	74건	3.1%	Tier 2
제94조(의견·동의)	72건	3.0%	Tier 2
제56조(연장 가산)	52건	2.2%	Tier 2
제24조(경영상 해고)	50건	2.1%	Tier 2

4. Tier 1 상세 내역

Tier 1은 독소조항이 가장 빈번하게 발생하는 핵심 조항으로, 10개 이상의 테마로 세밀하게 분류하였습니다. 테마 명칭은 [사실관계 + 법적 쟁점] 형식으로 작성하여 모델이 법리의 미세한 차이를 학습할 수 있도록 설계하였습니다.

조항	판례 수	테마 수	대표 수	주요 테마 예시
제2조(근로자)	469건	28개	28개	실질적 종속관계 기준 근로자성, 산재보험 급여 근로자성, 도급·위탁계약 근로자성 인정
제2조(평균임금)	197건	9개	9개	평균임금 산정 기초 임금 범위, 재요양 시 발생일 기준, 통상임금 구성항목 포함 여부
제2조(근로계약)	35건	7개	7개	포괄임금제 유효성, 전직·전출 동의 여부, 위약금 약정 효력
제23조(해고 제한)	294건	27개	27개	정당한 이유 없는 부당해고, 징계해고 절차 흠결, 전보·대기발령 정당성
제78조(요양 보상)	233건	21개	21개	산재보험 근로자성, 업무상 재해 상당인과관계, 과로·스트레스 기인 질병
제34조(퇴직급여)	183건	26개	26개	도급·위탁 근로자성 인정과 퇴직금, 계속근로연수 산정, 분할지급 약정 무효

4.1 주요 독소 패턴 유형 (Tier 1)

- 근로자성 판단: 도급·위탁·위촉계약 형식 악용, 독립계약자로 위장하여 퇴직금·4대보험 회피
- 임금 체계 조작: 포괄임금제 남용, 통상임금 고정성 결여 주장, 평균임금 산정 기초 축소
- 해고 절차 우회: 정당한 이유 없는 해고, 징계위원회 미개최, 서면 통지 생략
- 산재보상 회피: 업무와의 인과관계 부정, 특수형태 종사자 근로자성 부정
- 퇴직금 편법: 월급 분할 포함 약정, 중간정산 사전포기, 계속근로연수 단절 조작

5. Tier 2 상세 내역

Tier 2는 판례 10건 이상 조항으로, 주요 법적 쟁점에 따라 3~7개 테마로 분류하였습니다. 총 21개 조항에서 94개 테마, 94개 대표 판례가 추출되었습니다.

조항	판례 수	테마 수	주요 테마
제43조(임금 지급)	113건	8개	임금 체불 위반 요건, 지급기일 위반 형사처벌, 임금 공제·상계 금지, 금품의 임금 해당성
제50조(주 근로시간)	93건	7개	소정근로시간 합의 유효성, 대기시간 근로시간 해당성, 포괄임금제 근로시간 산정
제38조(우선 변제)	74건	7개	임금채권 최우선변제권 범위, 담보물권과의 충돌, 파산·회생에서의 우선순위
제94조(의견/동의)	72건	4개	불이익 변경 시 집단 동의 요건, 동의 방식 적법성, 신의칙·소급 적용
제56조(연장 가산)	52건	6개	포괄임금제 가산수당 청구, 휴일근로 가산율, 야간근로 가산 산정
제24조(경영상 해고)	50건	6개	긴박한 필요성 인정 기준, 해고 회피 노력 의무, 협의 의무 이행
제27조(서면 통지)	49건	4개	서면 미통지 해고 무효, 사유 미 기재 효력, 도달 방법과 요건
제28조(구제 신청)	37건	4개	제척기간 준수, 구제이의 존부, 금전보상명령 요건
제93조(취업규칙)	34건	4개	필수 기재사항, 단체협약 저촉, 징계·복무 규정 효력
제60조(연차 15일)	33건	6개	미사용 연차수당 청구권, 출근율 산정, 사용 촉진 면책
제96조(단체협약)	33건	5개	규범적 효력·구속력 범위, 유리 원칙, 유효기간 만료 후 효력
제30조(구제 명령)	29건	3개	원직복직 이행 기준, 금전보상 요건, 구제명령 소급 효력
제36조(금품 청산)	28건	5개	14일 내 청산 의무, 합의 연장 요건, 형사처벌 면책 사유
제6조(균등 처우)	27건	4개	성별·국적 차별 금지, 정규직·비정규직 임금 차별, 동일 가치 노동
제44조(도급 책임)	20건	5개	직상 수급인 연대 책임, 원청 임금 보호 책임, 직접 청구권
제5조(준수 의무)	19건	2개	5인 미만 사업장 적용 제한, 강행규정성
제82조(유족 보상)	18건	3개	유족 수급 자격·순위, 업무상 사망 요건, 손해배상 중복 조정
제15조(위반 계약)	15건	2개	위반 조항 무효와 법정 기준 적용, 포괄임금 불이익 조항
제26조(해고 예고)	15건	3개	예고 30일·수당 요건, 수습근로자 적용, 근로자 귀책 예외
제55조(주휴일)	15건	3개	주휴수당 지급 요건, 법정공휴일 유급화, 사업장 규모별 적용
제37조(지연 이자)	11건	3개	지연이자율 20% 적용, 퇴직금 지연이자, 법적 다툼 시 제외

6. Tier 3 상세 내역

Tier 3은 판례 10건 미만 희소 조항으로, 테마를 별도 분류하지 않고 조항명 자체를 테마로 사용합니다. 총 44개 조항에서 조항별 대표 판례 1개씩 추출하였습니다.

조항명	건수	조항명	건수	조항명	건수
제46조(휴업수당)	9건	제22조(강제저금 금지)	9건	제53조(연장 합의)	8건
제10조(공민권 보장)	6건	제20조(위약 예정 금지)	5건	제11조(적용 범위)	5건
제80조(장해 보상)	5건	제18조(단시간 조건)	5건	제47조(임금 보장)	5건
제1조(목적)	5건	제95조(감급 제한)	4건	제76조(괴롭힘 금지)	4건
제7조(강제근로 금지)	3건	제4조(자유 결정)	3건	제33조(이행강제금)	3건
제8조(폭행 금지)	3건	제42조(서류 보존)	3건	제54조(휴게 시간)	3건
제21조(전차금 상계)	3건	그 외 25개 조항	각 1~2건		

6.1 Tier 3 처리 원칙

- 테마명: 조항 키워드를 그대로 사용 (예: "휴업수당", "강제저금 금지")
- 대표 판례: 판례내용 길이 기준 가장 풍부한 사례 1 개 선정
- Hard Negative: 다른 조항 대표 판례를 활용 (같은 조항 내 다른 테마 없으므로)
- Easy Negative: 법적 쟁점이 완전히 다른 조항의 판례 무작위 선정

7. 산출 파일

본 프로젝트에서 생성된 최종 산출 파일은 아래와 같습니다.

파일명	항목 수	설명
제2조_전체_테마분류.json	701건	Tier 1: 제2조 전체 판례 테마 분류
제2조_크로스인코더_학습데이터.json	44개	Tier 1: 제2조 테마별 대표 + 학습 페어
제23조_전체_테마분류.json	294건	Tier 1: 제23조 전체 판례 테마 분류
제23조_크로스인코더_학습데이터.json	27개	Tier 1: 제23조 테마별 대표 + 학습 페어
제78조_전체_테마분류.json	233건	Tier 1: 제78조 전체 판례 테마 분류
제78조_크로스인코더_학습데이터.json	21개	Tier 1: 제78조 테마별 대표 + 학습 페어
제34조_전체_테마분류.json	183건	Tier 1: 제34조 전체 판례 테마 분류
제34조_크로스인코더_학습데이터.json	26개	Tier 1: 제34조 테마별 대표 + 학습 페어
전체_테마분류_완전본.json	2,369건	전체 판례 + 테마 태그 (조항 오름차순)
전체_테마별_대표판례.json	256개	모든 조항 × 테마별 대표 판례 1개씩
전체_크로스인코더_학습데이터.json	256항목	최종 학습 데이터 (768 학습 페어)

7.1 최종 데이터셋 병합 구조

- 전체_크로스인코더_학습데이터.json = Tier1(4 개 조항) + Tier2(21 개 조항) + Tier3(44 개 조항)
- 인코딩: UTF-8 (ensure_ascii=False), indent=2
- 정렬 기준: 근로기준법 조항 번호 오름차순
- 각 조항 파일은 독립적으로도 사용 가능

7.2 모델 학습 활용 가이드

- 권장 모델: klue/bert-base 또는 upskyy/kf-deberta-multitask 기반 크로스 인코더
- 입력 형식: [CLS] toxic_clause [SEP] content [SEP]
- 레이블: 0 (비관련) / 1 (관련)
- 배치 크기: 16~32, 학습률: 2e-5~5e-5 권장
- hard_negative 를 포함한 balanced sampling 적용 권장

7.3 데이터 품질 특성

- 실제 법원 판례 요약 텍스트를 **positive**로 활용하여 법적 근거 명확
- **hard_negative**는 동일 조항 내 다른 쟁점 판례 활용으로 세밀한 구분 능력 훈련
- 독소 계약 문구는 실제 계약서에서 출현 가능한 패턴 기반으로 작성
- 구법 조항 보정 및 중복 제거로 데이터 정확도 확보

7.4 추가 개선 제안

- 실제 근로계약서 독소 사례 수집 후 **toxic_clause** 추가 증강 권장
- **Tier 1** 조항(제 2 조·제 23 조 등) 판례 오버샘플링으로 데이터 불균형 보정 고려
- 추후 법령 조문 원문(**positive**)과 판례(**positive**)를 혼합하는 앙상블 구조 검토 가능

근로기준법 판례 기반 크로스 인코더 데이터셋 생성 완료

Tier 1 118개 | Tier 2 94개 | Tier 3 44개 | 총 256개 | 학습 페어 768쌍